

# Breast Cancer Diagnostic Classification

Nikol Vidaković, RA232/2023

Fakultet tehničkih nauka, Novi Sad

## 1. Opis problema


Cilj projekta je binarna klasifikacija tumora dojke (benigni / maligni) na osnovu 30 numeričkih karakteristika ćelijskog jezgra, dobijenih digitalizacijom slika biopsija (Wisconsin Breast Cancer dataset, 569 uzoraka). U medicinskom kontekstu propuštanje malignog slučaja je znatno opasnije od lažne uzbune, pa je maligni tumor tokom celog projekta tretiran kao pozitivna klasa, što direktno utiče na izbor metrike za poređenje modela.

## 2. Početno preprocesiranje podataka

Dataset je proveren na nedostajuće vrednosti i duplikate: pronađeno je 0 u oba slučaja, na svih 569 uzoraka. Kolona `id` je uklonjena, pošto predstavlja samo identifikator pacijenta bez ikakve dijagnostičke vrednosti. Ciljna promenljiva `diagnosis` je enkodirana iz tekstualnog (M/B) u numerički format: maligni (M) postaje 1, benigni (B) postaje 0. Dataset je blago neuravnotežen (357 benignih / 212 malignih, odnosno 62.7% / 37.3%), što je uzeto u obzir kroz stratifikaciju prilikom podele podataka i unakrsne validacije.

## 3. Eksplorativna analiza skupa

Statistička analiza je pokazala da atributi imaju vrlo različite skale (npr. `mean radius` u opsegu ~7-28 naspram `mean area` do ~2500), što je motivisalo naknadno skaliranje. Korelaciona analiza je pokazala da atributi iz "worst" grupe (najekstremnije izmerene vrednosti) najjače koreliraju sa dijagnozom (`worst concave points`  $r=0.79$ , `worst perimeter`  $r=0.78$ ), dok atributi iz "se" grupe (standardna greška) pokazuju zanemarljivu korelaciju (npr. `symmetry se`  $r=-0.007$ ). Nisu uočene ekstremne vrednosti koje bi ukazivale na greške u merenju. Na osnovu ovih nalaza, odluka o eventualnom uklanjanju atributa je odložena do faze odabira najznačajnijih atributa, gde se zasniva na konkretnim, izmerenim pokazateljima važnosti.



Slika 1 — Korelaciona matrica svih atributa

## 4. Odabir i treniranje modela

Podaci su podeljeni na trening (80%) i test (20%) skup uz stratifikaciju ( `stratify=y` ), kako bi oba skupa zadržala isti odnos klasa kao originalni dataset. Atributi su skalirani pomoću `StandardScaler` -a, fitovanog isključivo na trening skupu radi sprečavanja data leakage-a.

Upoređeno je pet algoritama za binarnu klasifikaciju: logistička regresija, KNN, SVM, stablo odlučivanja i Random Forest, svaki sa podrazumevanim hiperparametrima. Svaki model je ocenjen kroz unakrsnu validaciju sa 5 podskupova (5-fold cross-validation): trening skup se podeli na 5 delova, i u 5 krugova se model trenira na 4 dela, a testira na preostalom delu, tako da svaki deo jednom posluži za testiranje. Rezultati se zatim usrednje, što daje pouzdaniju procenu nego jedna jedina podela podataka.

| Model                | CV Recall |
|----------------------|-----------|
| SVM                  | 0.959     |
| Logistička regresija | 0.953     |
| Random Forest        | 0.941     |
| KNN                  | 0.918     |
| Stablo odlučivanja   | 0.894     |

Logistička regresija i SVM su se pokazali kao najjači kandidati već u ovoj fazi, što ukazuje da su klase u dataset-u u velikoj meri linearno razdvojive, dok je stablo odlučivanja pokazalo najslabije rezultate, u skladu sa očekivanjem da pojedinačno stablo nije dovoljno stabilno za pouzdanu predikciju.

## 5. Analiza rezultata predikcije i izbor metrike

Kao glavni kriterijum za poređenje i izbor modela korišćen je **recall**, umesto accuracy, precision, F1 ili ROC-

AUC. Razlog je direktna veza sa kliničkim kontekstom problema: recall meri koliko je model uspeo da pronađe od svih stvarno malignih slučajeva, što je tačno ono pitanje koje je najrelevantnije kada je propuštanje pozitivnog slučaja opasnije od lažne uzbune.

Ostale metrike nisu jednako pogodne kao primarni kriterijum. Accuracy tretira obe vrste grešaka (lažnu uzbunu i propušten slučaj) kao podjednako loše, a u ovom problemu to nije slučaj: jedna greška je mnogo ozbiljnija od druge. Precision bi kao primarni kriterijum vodio ka modelu koji je “previše oprezan” pri proglašavanju maligniteta, čime bi rastao rizik od propuštenih slučajeva. F1 traži ravnotežu između precision i recall, a ovde se svesno teži pristrasnosti ka pronalaženju što više pozitivnih slučajeva, ne ravnoteži. ROC-AUC ocenjuje model preko svih mogućih pragova odlučivanja, ali ne specifično preko praga (0.5) koji se stvarno koristi u praksi. Sve četiri metrike su i dalje praćene i izveštavane radi potpunije slike, ali recall određuje konačno rangiranje modela.

## 6. Podešavanje hiperparametara

Za tri najbolja modela po CV recall-u (SVM, logistička regresija, Random Forest) sprovedena je sistematična pretraga hiperparametara ( `GridSearchCV` , `scoring="recall"` , petostruka unakrsna validacija). Za SVM su testirane vrednosti `C` ∈ {0.1, 1, 10, 100} i `kernel` ∈ {linear, rbf}; za logističku regresiju `C` ∈ {0.01, 0.1, 1, 10, 100}; za Random Forest `n_estimators` ∈ {100, 200, 300} i `max_depth` ∈ {None, 5, 10, 15}.


| Model                | Najbolji hiperparametri       | CV Recall |
|----------------------|-------------------------------|-----------|
| SVM                  | C=10, kernel=rbf              | 0.965     |
| Logistička regresija | C=1                           | 0.953     |
| Random Forest        | max_depth=5, n_estimators=100 | 0.947     |

SVM sa optimizovanim hiperparametrima je izabran kao finalni model, sa najvišim CV recall-om od sva tri kandidata.

**Finalne metrike na test skupu** (114 pacijenata, nikad viđenih tokom treniranja):

| Metrika  | CV (trening) | Test skup |
|----------|--------------|-----------|
| Recall   | 0.965        | 0.929     |
| Accuracy | 0.976        | 0.974     |
| F1       | 0.967        | 0.963     |
| ROC-AUC  | 0.995        | 0.993     |

Matrica konfuzije na test skupu pokazuje da model nije napravio nijednu lažnu uzbunu (0 benignih pogrešno označeno kao maligno), dok je propustio 3 od 42 stvarno maligna slučaja — to su konkretni slučajevi koje bi u realnoj primeni trebalo dodatno klinički proveriti.




Slika 2 — Matrica konfuzije finalnog modela

## 7. Odabir najznačajnijih atributa

SVM sa `rbf` kernelom ne nudi direktan uvid u to koliko je svaki atribut doprineo predikciji, pa je za procenu važnosti atributa iskorišćen Random Forest, koji takvu informaciju prirodno daje kroz proces treniranja.

Najvažniji atributi pokazali su se kao `worst area`, `worst concave points`, `worst radius`, `worst perimeter` i `mean concave points`: gotovo sva mesta u vrhu zauzimaju atributi iz “worst” grupe, dok se nijedan atribut iz “se” grupe nije našao među deset najvažnijih. Ovo je u skladu sa onim što je uočeno još u eksplorativnoj analizi: “worst” vrednosti nose najviše korisne informacije za razlikovanje benignih i malignih slučajeva.



Slika 3 — Deset najvažnijih atributa prema Random Forest-u

## 8. Deployment modela

---

Finalni model (SVM sa optimizovanim hiperparametrima) je sačuvan zajedno sa fitovanim `StandardScaler`-om u jedinstven `sklearn.pipeline.Pipeline` objekat, eksportovan pomoću `joblib` biblioteke u fajl `models/breast_cancer_svm.joblib`. Ovaj pristup obezbeđuje da se skaliranje automatski primenjuje na nove podatke pre predikcije, bez rizika da korisnik sačuvanog modela zaboravi ili pogrešno primeni taj korak.

Korišćenje modela je omogućeno kroz tri kanala:

- `src/predict.py` — skripta koja demonstrira učitavanje sačuvanog modela i predikciju na jednom novom primeru, bez ponovnog treniranja
- **Streamlit aplikacija** (`app/ui.py`) — vizuelna web forma sa unosom podataka grupisanim u tri sekcije (mean/se/worst), mogućnošću brzog popunjavanja stvarnim primerima pacijenata iz dataset-a, i prikazom predviđene klase sa verovatnoćama
- **FastAPI servis** (`app/api.py`) — REST API sa rutama `GET /` (provera statusa) i `POST /predict` (predikcija na osnovu poslatih podataka pacijenta, validiranih kroz Pydantic model), sa automatski generisanom interaktivnom dokumentacijom na ruti `/docs`

Sva tri kanala su testirana na poznatim uzorcima iz dataset-a i potvrđeno je da daju identičnu, ispravnu predikciju.

## Zaključak

---

Razvijen je kompletan tok rada za binarnu klasifikaciju dijagnoze tumora dojke: preprocesiranje, eksplorativna analiza, poređenje pet algoritama kroz unakrsnu validaciju, fino podešavanje hiperparametara, odabir najznačajnijih atributa, i deployment finalnog modela kroz dva nezavisna kanala (UI i API). Finalni model (SVM, C=10, kernel=rbf) postiže recall od 0.929 i accuracy od 0.974 na test skupu, uz nijednu lažnu uzbunu i samo 3 propuštena slučaja od ukupno 42 maligna uzorka u test skupu. Analiza važnosti atributa je pokazala da osobine iz “worst” grupe nose najviše korisne informacije za ovaj problem, što otvara mogućnost za dalje pojednostavljenje modela u budućim iteracijama.